GBDT算法甄别某电商的高质量用户

实验目标

通过本案例的学习和课后作业的练习:

- 1. 通过代码的实现,帮助大家快速理解机器学习整个流程;
- 2. 能够使用SKlearn实现GBDT算法。

你也可以将本案例相关的 ipynb 学习笔记分享到 Al Gallery Notebook (https://marketplace.huaweicloud.com/markets/aihub/notebook/list/) 版块获得成长值 (https://marketplace.huaweicloud.com/markets/aihub/article/detail/?content_id=9b8d7e7a-a150-449e-ac17-2dcf76d8b492), 分享方法请查看此文档 (https://marketplace.huaweicloud.com/markets/aihub/article/detail/?content_id=8afec58a-b797-4bf9-acca-76ed512a3acb)。

案例内容介绍

梯度提升决策树(Gradient Boosting Decision Tree, GBDT)算法属于集成算法的一种,基分类器是回归树(分类问题也是回归树,最后再用sigmoid或者softmax函数计算类别),是一种boosting算法,即逐步拟合逼近真实值,是一个串行的算法,可以减少bias(误差)却不能减少variance(偏差),因为每次基本都是全样本参与训练,不能消除偶然性的影响,但每次都逐步逼近真实值,可以减少误差。

GBDT包括三种基本用法,一是回归,二是二分类,三是多分类。技术细节有点差异,但是整体思路都是一样的。

该算法是近年来被提及的比较多,这主要得益于其算法的性能,以及该算法在各类数据挖掘以及机器学习比赛中的卓越表现,有很多人对GBDT算法进行了开源代码的开发,比较火的是陈天奇的XGBoost和微软的 LightGBM。

本案例推荐的理论学习视频:

• <u>《AI技术领域课程--机器学习》 GBDT (https://education.huaweicloud.com/courses/course-v1:HuaweiX+CBUCNXE086+Self-paced/courseware/f56ce3bf3bc84b4e80dce98cd5dbf2ca</u>/d765dbae0f5e4c69936fe8fe0474ebd9/)

注意事项

1. 如果您是第一次使用 JupyterLab, 请查看<u>《ModelArts JupyterLab使用指导》</u>
(<a href="https://marketplace.huaweicloud.com/markets/aihub/article/detail/?content_id=03676d0a-0630-4a3f-b62c-07fba43d2857]]

b62c-07fba43d2857]了解使用方法;

2. 如果您在使用 JupyterLab 过程中碰到报错,请参考<u>《ModelArts JupyterLab常见问题解决办法》</u> (<a href="https://marketplace.huaweicloud.com/markets/aihub/article/detail/?content_id=9ad8ce7d-06f7-4394-80ef-4dbf6cfb4be1]尝试解决问题。

实验步骤

1、导入相关库

```
In [1]: import numpy as np
   import pandas as pd
   import matplotlib.pyplot as plt
   from sklearn import datasets
   %matplotlib inline
```

2、读取用户数据

INFO:root:Using OBS-Python-SDK-3.20.7

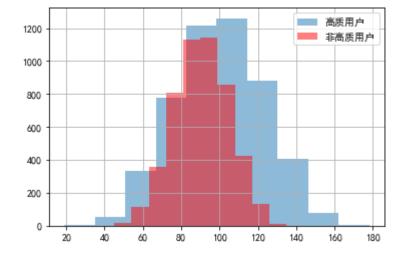
INFO:root:Using MoXing-v1.17.3-

Out[3]:

		用户标 识符	网络类型	类目1 消费 金额	类目2 消费 金额	类目3 消费 金额	类目 4消 费金 额	类目5 消费 金额	类目6 消费 金额	类目 7消 费金 额	类目7 消费金 额.1	总消 费次 数	账户 余额	是否 高质 用户
	0	66069	3G	70	97	395	13	64	168	59	465	7	36	0
	1	64410	3G	94	79	366	35	59	182	70	542	13	66	0
;	2	60110	3G	92	99	390	44	134	219	8	548	8	110	1
;	3	69600	4G	131	87	391	0	128	180	63	498	4	30	1
	4	64683	4G	74	104	397	35	112	258	68	614	15	18	1

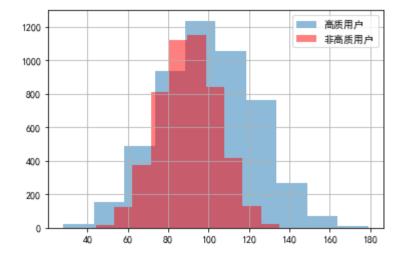
```
In [4]: # 不同用户的类目1消费金额分布情况对比
cond = data['是否高质用户'] == 1
data[cond]['类目1消费金额'].hist(alpha=0.5, label='高质用户')
data[~cond]['类目1消费金额'].hist(color='r', alpha=0.5, label='非高质用户')
plt.legend()
```

Out[4]: <matplotlib.legend.Legend at 0x7f9dfaa906a0>



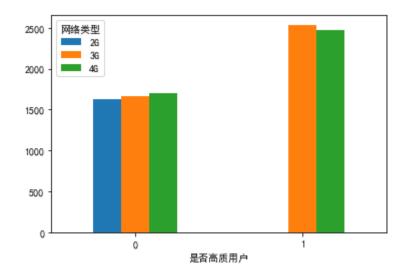
第3页 共11页 2021/11/24 14:38

Out[5]: <matplotlib.legend.Legend at 0x7f9dfaa04e80>



In [6]: # 不同用户的网络类型情况对比 grouped = data.groupby(['是否高质用户', '网络类型'])['用户标识符'].count().u nstack() grouped.plot(kind='bar', alpha=1.0, rot=0)

Out[6]: <matplotlib.axes. subplots.AxesSubplot at 0x7f9df8302630>



```
In [7]: data['是否高质用户'].value_counts()
```

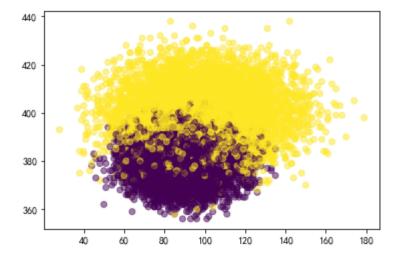
Out[7]: 1 5003 0 4997

Name: 是否高质用户, dtype: int64

第4页 共11页 2021/11/24 14:38

```
In [8]: # 生成数据可视化
y = data.loc[:, '是否高质用户']
plt.scatter(data.loc[:, '类目2消费金额'], data.loc[:, '类目3消费金额'], c=
y, alpha=0.5)
```

Out[8]: <matplotlib.collections.PathCollection at 0x7f9df5afb400>



3、数据预处理

```
In [9]:  # 类别特征编码
    X = data.loc[:, '网络类型':'账户余额']
    y = data.loc[:, '是否高质用户']
    print('The shape of X is {0}'.format(X.shape))
    print('The shape of y is {0}'.format(y.shape))

The shape of X is (10000, 11)
```

The shape of y is (10000,)

In [10]: X.head()

Out[10]:

	网络 类型	类目1消 费金额	类目2消 费金额	类目3消 费金额	类目4 消费金 额	类目5消 费金额	类目6消 费金额	类目7 消费金 额	类目7消 费金额.1	^{忌消} 费次 数	账户 余额	
0	3G	70	97	395	13	64	168	59	465	7	36	
1	3G	94	79	366	35	59	182	70	542	13	66	
2	3G	92	99	390	44	134	219	8	548	8	110	
3	4G	131	87	391	0	128	180	63	498	4	30	
4	4G	74	104	397	35	112	258	68	614	15	18	

第5页 共11页 2021/11/24 14:38

```
In [11]: from sklearn.preprocessing import OneHotEncoder
         def service mapping(cell):
            if cell == '2G':
                return 2
            elif cell == '3G':
               return 3
            elif cell == '4G':
                return 4
         # 将网路类型的string型值映射为整数型
         service map = X['网络类型'].map(service mapping)
         service = pd.DataFrame(service map)
         # service df
         # 使用OncHotEncoder转化类型特征为0/1编码的多维特征
         enc = OneHotEncoder()
         service_enc = enc.fit_transform(service).toarray()
         service enc
         # 0/1编码的多维特征的名称
         service names = enc.active features .tolist()
         service newname = [str(x) + 'G' for x in service names]
         service df = pd.DataFrame(service enc, columns=service newname)
         service df.head()
         X enc = pd.concat([X, service df], axis=1).drop('网络类型', axis=1)
         X enc.head()
```

第6页 共11页 2021/11/24 14:38

/home/ma-user/anaconda3/envs/XGBoost-Sklearn/lib/python3.6/site-packa ges/sklearn/preprocessing/_encoders.py:363: FutureWarning: The handli ng of integer data will change in version 0.22. Currently, the catego ries are determined based on the range [0, max(values)], while in the future they will be determined based on the unique values.

If you want the future behaviour and silence this warning, you can sp ecify "categories='auto'".

In case you used a LabelEncoder before this OneHotEncoder to convert the categories to integers, then you can now use the OneHotEncoder directly.

warnings.warn(msg, FutureWarning)

/home/ma-user/anaconda3/envs/XGBoost-Sklearn/lib/python3.6/site-packa ges/sklearn/utils/deprecation.py:77: DeprecationWarning: Function act ive_features_ is deprecated; The ``active_features_`` attribute was d eprecated in version 0.20 and will be removed 0.22.

warnings.warn(msg, category=DeprecationWarning)

Out[11]:

	类目1 消费金 额	类目2 消费金 额	类目3 消费金 额	类目4 消费 金额	类目5 消费金 额	类目6 消费金 额	类目7 消费 金额	类目7 消费金 额.1	总消 费次 数	账户 余额	2G	3G	4G
0	70	97	395	13	64	168	59	465	7	36	0.0	1.0	0.0
1	94	79	366	35	59	182	70	542	13	66	0.0	1.0	0.0
2	92	99	390	44	134	219	8	548	8	110	0.0	1.0	0.0
3	131	87	391	0	128	180	63	498	4	30	0.0	0.0	1.0
4	74	104	397	35	112	258	68	614	15	18	0.0	0.0	1.0

4、训练准备过程

第7页 共11页 2021/11/24 14:38

```
In [12]: from sklearn.model selection import cross val score
         from sklearn.model selection import train test split, GridSearchCV
         from sklearn.ensemble import GradientBoostingClassifier
         from xqboost import XGBClassifier
         from sklearn import metrics
         # 分割训练集和测试集
         X train, X test, y train, y test = train test split(X enc, y, test size
         =0.2, random state=112)
         print('The shape of X train is {0}'.format(X train.shape))
         print('The shape of X test is {0}'.format(X test.shape))
         print('The shape of y train is {0}'.format(y train.shape))
         print('The shape of y test is {0}'.format(y test.shape))
         # 生成数据可视化
         plt.scatter(X train.iloc[:, 0], X train.iloc[:, 1], c=y train, alpha=0.
         5)
         # 交叉验证
         def modelfit(alg, X train, y train, performCV=True, printFeatureImporta
         nce=True, cv folds=5):
             alg.fit(X_train, y_train)
             # Predict training set:
             train predictions = alg.predict(X train)
             train predprob = alg.predict proba(X train)[:, 1]
             # Perform cross-validation: here the author calculate cross-validate
         d AUC
             if performCV:
                 cv score = cross val score(alg, X train, y train, cv=cv folds,
         scoring='roc auc')
             # Print model report:
             print("\nModel Report")
             print("Accuracy (Train): %3.4f" % metrics.accuracy score(y train.va
         lues, train predictions))
             ## IMPORTANT: first argument is true values, second argument is pre
         dicted probabilities
             print("AUC Score (Train): %f" % metrics.roc auc score(y train, trai
         n predprob))
             if performCV:
                 print("CV Score: Mean - %.7g | Std - %.7g | Min - %.7g | Max -
                       % (np.mean(cv score), np.std(cv score), np.min(cv score),
         np.max(cv score)))
             # Print Feature Importance:
             if printFeatureImportance:
                 feat imp = pd.Series(alg.feature importances , X train.columns.
         tolist()).sort values(ascending=True)
                 feat imp.plot(kind='barh', title='Feature Importances')
                 plt.ylabel('Feature Importance Score')
                 = plt.xlabel('Relative importance')
```

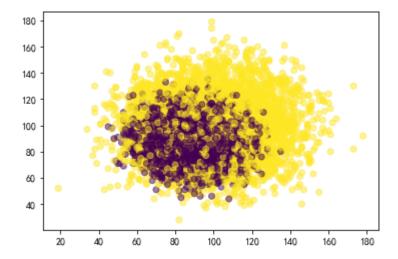
第8页 共11页 2021/11/24 14:38

The shape of X_train is (8000, 13)

The shape of X_test is (2000, 13)

The shape of y_train is (8000,)

The shape of y_test is (2000,)



5、GBDT模型训练及预测

第9页 共11页 2021/11/24 14:38

```
In [13]: from pylab import mpl
        mpl.rcParams['font.sans-serif'] = ['SimHei'] # 指定默认字体
        mpl.rcParams['axes.unicode minus'] = False # 解决保存图像是负号'-'显示为方
        块的问题
         # 模型实例化
        clf0 = GradientBoostingClassifier(random state=110)
         # 在训练集上训练模型
        clf0.fit(X train, y train)
         # 在测试集上预测
        y pred = clf0.predict(X test)
         # 计算准备; 率
        score = metrics.accuracy score(y test, y pred)
        print('The accuracy score of the model is: {0}'.format(score))
        # 查看混淆举证
        metrics.confusion matrix(y test, y pred)
         # #模型实例化
        clf0 = GradientBoostingClassifier(random state=110)
        modelfit(clf0, X train, y train)
```

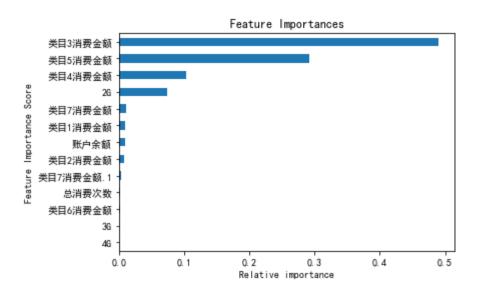
The accuracy score of the model is: 0.9825

Model Report

Accuracy (Train): 0.9862

AUC Score (Train): 0.999099

CV Score: Mean - 0.9975603 | Std - 0.0004027038 | Min - 0.9969856 | Max - 0.9979951



第10页 共11页 2021/11/24 14:38

小结

本实验基于脱敏后的某电商用户消费数据,使用GBDT算法根据用户的行为特征帮助甄别是否高质量用户,可以看到模型的分类准确率可以达到0.9825,可以根据实际业务指标来判断模型是否达到了需要,可以通过后续的多种策略(超参数选择,模型剪枝等)进行模型性能的提升。

以上是 GBDT 的实现方法,受限于篇幅原因,本案例未完全覆盖 GBDT 的全部操作,欢迎你将更全面的 GBDT 学习笔记分享到 AI Gallery Notebook (https://marketplace.huaweicloud.com/markets/aihub/notebook /list/) 版块获得成长值 (https://marketplace.huaweicloud.com/markets/aihub/article/detail /?content_id=9b8d7e7a-a150-449e-ac17-2dcf76d8b492),分享方法请查看此文档 (https://marketplace.huaweicloud.com/markets/aihub/article/detail/?content_id=8afec58a-b797-4bf9-acca-76ed512a3acb)。

作业

请你利用本实验中学到的知识点,完成以下编程题:

- 1. <u>请你尝试修改 GradientBoostingClassifier() 函数的 n_estimators (基学习器个数) 参数的不同取值,看看 该参数的修改对模型会有怎样的影响。 (https://marketplace.huaweicloud.com/markets/aihub/notebook/detail/?id=4ce69a2b-e194-46d1-8ea5-4cf92746d912)</u>
- 2. 请你尝试修改 GradientBoostingClassifier() 函数的 max_depth (最大深度) 参数的不同取值,看看该参数的修改对模型会有怎样的影响。 (https://marketplace.huaweicloud.com/markets/aihub/notebook/detail/?id=284864aa-9262-4ce9-9316-6988f67392f8)
- 3. 请你尝试修改 GradientBoostingClassifier() 函数的所有可调参数的不同取值,看看不同参数的不同取值组合,对模型会有怎样的影响。 (https://marketplace.huaweicloud.com/markets/aihub/notebook/detail/?id=004a94cf-d628-42e7-b745-da5a47082eb5)